

CS-548 - Cloud-native Software Architectures

Assignment A3: Docker

Μάνος Αλέξανδρος csd-5136

Due Date: 06/04/2026

Άσκηση 1

a) To limit each Pod to a maximum of 20% CPU and 256MB RAM.

Προσθέτουμε στο τέλος του αρχείου hello-ingress.yaml το item resources με τα αντίστοιχα limits για CPU και Memory.

```
50 | | | | resources:
51 | | | | limits:
52 | | | |   cpu: "200m"
53 | | | |   memory: "256Mi"
54 | | | |
```

b) With a HorizontalPodAutoscaler manifest, which will increase the number of Pods in the Deployment when the average CPU usage exceeds 80%. Set a minimum of 1 Pod and a maximum of 8 for the Deployment.

Για το ερώτημα αυτό πρόσθεσα στο κομμάτι των resources τα requests, για να μπορέσει να υπολογίσει σωστά ο HorizontalPodAutoscaler το utilize.

```
50 | | | | resources:
51 | | | |   limits:
52 | | | |     cpu: "200m"
53 | | | |     memory: "256Mi"
54 | | | |   requests:
55 | | | |     cpu: "100m"
56 | | | |     memory: "128Mi"
```

Έπειτα προσθέσαμε τα όρια min/maxReplicas για να ορίσουμε τα όρια των αριθμών των pods και μετά το utilization.

```

  apiVersion: autoscaling/v2
  kind: HorizontalPodAutoscaler
  metadata:
    name: exerc-b
  spec:
    scaleTargetRef:
      apiVersion: apps/v1
      kind: Deployment
      name: hello
    minReplicas: 1
    maxReplicas: 8
    metrics:
      - type: Resource
        resource:
          name: cpu
          target:
            type: Utilization
            averageUtilization: 80

```

Έπειτα για το κομμάτι του http benchmark χρησιμοποίησα το

ab - Apache HTTP server benchmarking tool

(το πρώτο [benchmark](#) που εμφανίστηκε στο google search).

The commands used to test in minikube:

- (1) minikube start
(Addons)
- (2) minikube addons enable ingress
- (3) minikube addons enable metrics-server
Κάνουμε apply το yaml αρχείο
- (4) kubectl apply -f hello-ingress.yaml

```

ingress.networking.k8s.io/hello-ingress created
service/hello created
deployment.apps/hello created

```

και αφού πρώτα κάνουμε save το file και μετά apply, γιατί αλλιώς θα μας βγάλει
No resources found in default namespace.

Τρέχουμε το command:

- (5) kubectl get hpa

NAME	REFERENCE	TARGETS	MINPODS	MAXPODS	REPLICAS	AGE
exerc-b	Deployment/hello	cpu: <unknown>/80%	1	8	1	21s

αφου περιμένουμε λίγο το ξανα τρέχουμε:

NAME	REFERENCE	TARGETS	MINPODS	MAXPODS	REPLICAS	AGE
exerc-b	Deployment/hello	cpu: 4%/80%	1	8	1	3m16s

Για το benchmark τρέχουμε τις εξής εντολές:

(1) `kubectl get ingress`

Για να βρούμε την ip διεύθυνση

(2) `ab -n 1000 -c 1 http://192.168.49.2/hello`

Για να τρέξουμε 1.000 αιτήματα με έναν client (σαν close loop, ένα-ένα).

```
This is ApacheBench, Version 2.3 <$Revision: 1923142 $>
Copyright 1996 Adam Twiss, Zeus Technology Ltd, http://www.zeustech.net/
Licensed to The Apache Software Foundation, http://www.apache.org/

Benchmarking 192.168.49.2 (be patient)
Completed 100 requests
Completed 200 requests
Completed 300 requests
Completed 400 requests
Completed 500 requests
Completed 600 requests
Completed 700 requests
Completed 800 requests
Completed 900 requests
Completed 1000 requests
Finished 1000 requests


Server Software:
Server Hostname:      192.168.49.2
Server Port:          80

Document Path:        /hello
Document Length:      177 bytes

Concurrency Level:    1
Time taken for tests:  11.937 seconds
Complete requests:    1000
Failed requests:       0
Non-2xx responses:    1000
Total transferred:    448000 bytes
HTML transferred:     177000 bytes
Requests per second:  83.77 [#/sec] (mean)
Time per request:     11.937 [ms] (mean)
Time per request:     11.937 [ms] (mean, across all concurrent requests)
Transfer rate:        36.65 [Kbytes/sec] received
```

```

Connection Times (ms)
              min  mean[+/-sd] median  max
Connect:      0    0    0.1    0    0
Processing:    0   12   26.5    2   199
Waiting:      0   11   26.5    2   199
Total:        0   12   26.5    2   199

Percentage of the requests served within a certain time (ms)
 50%    2
 66%    2
 75%    3
 80%    3
 90%   71
 95%   83
 98%   91
 99%   95
100%  199 (longest request)

```

(3) `ab -n 100000 -c 150 http://192.168.49.2/hello`
 Για να τρέξουμε 1.00000 αιτήματα με 150 clientsέναν

```

Benchmarking 192.168.49.2 (be patient)
Completed 10000 requests
Completed 20000 requests
Completed 30000 requests
Completed 40000 requests

```

```

Assignment3: watch — Konsole
Every 2,0s: kubectl get hpa,pods
naxi: Wed Apr 1 19:15:14 2026

NAME                                REFERENCE          TARGETS          MINPODS  MAXPODS
REPLICAS  AGE
horizontalpodautoscaler.autoscaling/exerc-b  Deployment/hello   cpu: 198%/80%    1         8
2          32m

NAME                                READY  STATUS   RESTARTS  AGE
pod/hello-67cb445447-mslr8          1/1    Running   0          32m
pod/hello-67cb445447-pq8dz          1/1    Running   0          9s
pod/hello-67cb445447-qtgj2          1/1    Running   0          9s
pod/hello-67cb445447-tnbqc          1/1    Running   0          2m9s

```

(Δεν το έχω αφήσει να πικάρει το φορτίο ακόμα, για αυτό έχουμε λίγα pods).

```
Benchmarking 192.168.49.2 (be patient)
Completed 10000 requests
Completed 20000 requests
Completed 30000 requests
Completed 40000 requests
Completed 50000 requests
Completed 60000 requests
Completed 70000 requests
Completed 80000 requests
Completed 90000 requests
Completed 100000 requests
Finished 100000 requests

Server Software:
Server Hostname:      192.168.49.2
Server Port:          80

Document Path:        /hello
Document Length:      177 bytes

Concurrency Level:     150
Time taken for tests:   256.427 seconds
Complete requests:     100000
Failed requests:        8
  (Connect: 0, Receive: 0, Length: 8, Exceptions: 0)
Non-2xx responses:     100000
Total transferred:     44798656 bytes
HTML transferred:      17699784 bytes
Requests per second:   389.98 [#/sec] (mean)
Time per request:      384.640 [ms] (mean)
Time per request:      2.564 [ms] (mean, across all concurrent requests)
Transfer rate:         170.61 [Kbytes/sec] received

Connection Times (ms)
              min  mean[+/-sd] median   max
Connect:        0    0   0.8      0     22
Processing:      0  384 467.8    166   3598
Waiting:         0  384 467.8    165   3598
Total:          0  384 467.8    166   3599

Percentage of the requests served within a certain time (ms)
 50%    166
 66%    428
 75%    684
 80%    791
 90%   1003
 95%   1331
 98%   1689
 99%   1903
100%   3599 (longest request)
```

Μετά την εκτέλεση:

```
Every 2,0s: kubectl get hpa,pods
```

NAME		REFERENCE	TARGETS	MINPODS	MAXPODS
REPLICAS	AGE				
horizontalpodautoscaler.autoscaling/exerc-b	8	Deployment/hello	cpu: 128%/80%	1	8
	35m				

NAME	READY	STATUS	RESTARTS	AGE
pod/hello-67cb445447-4ccpb	1/1	Running	0	31s
pod/hello-67cb445447-7zf7b	1/1	Running	0	31s
pod/hello-67cb445447-hdw6k	1/1	Running	0	2m16s
pod/hello-67cb445447-mslr8	1/1	Running	0	34m
pod/hello-67cb445447-nx8qn	1/1	Running	0	31s
pod/hello-67cb445447-pq8dz	1/1	Running	0	2m31s
pod/hello-67cb445447-qtgj2	1/1	Running	0	2m31s
pod/hello-67cb445447-tnbqc	1/1	Running	0	4m31s

Στο benchmark με 1 client, το σύστημα έτρεχε με 1 Pod και μπόρεσε να διαχειριστεί ~84 requests το δευτερόλεπτο (section Requests per second).

Στο benchmark με 150 ταυτόχρονους clients, ο HorizontalPodAutoscaler είδε ότι το utilization της CPU ξεπέρασε το 80%. Έτσι έκανε scale up τον αριθμό των Pods στα 8, όσο είναι δηλαδή το upper limit (αυτό φαίνεται στο πιο πάνω screenshot, όπου πρόλαβαν να σηκωθούν και τα 8).

(4) watch -n 2 kubectl get hpa,pods

Είναι η εντολή “kubectl get hpa,pods” κάθε 2 δευτερόλεπτα.

Η απόδοση τώρα έφτασε ~390 requests το δευτερόλεπτο. Ωστόσο είχαμε και απώλεια 8 πακέτων.

Με κάτι πιο ελαφρύ 10000 αιτήματα με 20 clients, βλέπουμε ότι έχουμε 20 pods:

NAME		REFERENCE	TARGETS	MINPODS	MAXPODS
REPLICAS	AGE				
horizontalpodautoscaler.autoscaling/exerc-b	2	Deployment/hello	cpu: 103%/80%	1	8
	95m				

NAME	READY	STATUS	RESTARTS	AGE
pod/hello-67cb445447-fgvsx	1/1	Running	0	97s
pod/hello-67cb445447-mslr8	1/1	Running	0	95m

Άσκηση 2

a) The string to return (use the MESSAGE environment variable).

Ακολουθώντας την ενότητα [The Chart File Structure](#) δημιουργούμε το directory templates και τα αρχεία Chart.yaml και values.yaml ή απλά τρέχουμε την εντολή
(1) helm create exerc2

```
alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3$ helm create exerc2
Creating exerc2
alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3$ ls exerc2/
Chart.yaml  charts  templates  values.yaml
```

Καθαρίζουμε τον φάκελο templates και έπειτα προσθέτουμε στο values.yaml κάτω κάτω το message:

```
161 affinity: {}
162
163 message: "Hello world"
164
```

Έπειτα, μέσα στο templates directory προσθέτουμε το .yaml αρχείο και προσθέτουμε στο env την μεταβλητή MESSAGE:

```
45 env:
46   - name: HANDLER_PATH_PREFIX
47     value: /hello
48   - name: RENDER_PATH_PREFIX
49     value: /hello
50   - name: MESSAGE
51     value: {{ .Values.message | quote }}
52 resources:
53   limits:
54     cpu: "200m"
55     memory: "256Mi"
56   requests:
57     cpu: "100m"
58     memory: "128Mi"
```

Note: το | quote είναι επειδή στην αρχή μου πετούσε error και δεν ήξερα το γιατί, αλλά ήταν επειδή το string message ήταν κενό.

b) The endpoint to use for the service (currently /hello).

Για το ερώτημα αυτό, δηλώνουμε στο αρχείο values.yaml το endpoint:

endpoint: "/hello"

Στο αρχείο .yaml που βρίσκεται στο templates directory, κάνουμε αντικατάσταση: το path στο Ingress και τα value στο Deployment στα specS

```
5 spec:
6   rules:
7     - http:
8       paths:
9         - path: {{ .Values.endpoint | quote }}
10           pathType: Prefix
11           backend:
12             service:
13               name: hello
14               port:
15                 number: 8080

42 containers:
43   - name: hello-kubernetes
44     image: carvicsforth/hello-kubernetes:1.10
45     env:
46       - name: HANDLER_PATH_PREFIX
47         value: {{ .Values.endpoint | quote }}
48       - name: RENDER_PATH_PREFIX
49         value: {{ .Values.endpoint | quote }}
50       - name: MESSAGE
51         value: {{ .Values.message | quote }}
52     resources:
```

c) The CPU and memory limits of each Pod (optional, default is no limits).

Ορίζουμε στο values.yaml αρχείο τις μεταβλητές limCPU και limMemory.

Για το κομμάτι του optional όρισα τα εξής if-statement ακολουθώντας το [παράδειγμα](#) και το [Flow Control](#) στο αρχείο .yaml του templates.

Έτσι στο if-statement πρόσθεσα και τα dashes

First, the curly brace syntax of template declarations can be modified with special characters to tell the template engine to chomp whitespace. `{{- }}` (with the dash and space added) indicates that whitespace should be chomped left, while `-}}` means whitespace to the right should be consumed. *Be careful! Newlines are whitespace!*

Οπότε στο αρχείο .yaml στα resources:

```
52 resources:
53     {{- if or .Values.limCPU .Values.limMemory }}
54     limits:
55         {{- if .Values.limCPU }}
56         cpu: {{ .Values.limCPU | quote }}
57         {{- end }}
58         {{- if .Values.limMemory }}
59         memory: {{ .Values.limMemory | quote }}
60         {{- end }}
61     {{- end }}
62     requests:
63     cpu: "100m"
64     memory: "128Mi"
65 ---
```

(d) The maximum number of Deployment Pods for the HorizontalPodAutoscaler (optional, default is 10).

Στην αρχή, την default τιμή την όρισα μέσα στο value.yaml, όμως καλύτερα να την ορίσεις στο template. Οπότε στο values.yaml όρισα την μεταβλητή maxPods και στο template άλλαξα την γραμμή maxReplicas, από 8 που την είχαμε πριν σε maxReplicas: {{ default 10 .Values.maxPods }}

Τελευταίο σκέλος της άσκησης:

```
helm install goodbye . \
--set message="Goodbye world!" \
--set endpoint="/goodbye" \
--set limCPU="250m" \
--set maxPods=20
```

```
alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3/exerc2$ helm install goodbye . \
--set message="Goodbye world!" \
--set endpoint="/goodbye" \
--set limCPU="250m" \
--set maxPods=20
NAME: goodbye
LAST DEPLOYED: Wed Apr 1 23:29:38 2026
NAMESPACE: default
STATUS: deployed
REVISION: 1
DESCRIPTION: Install complete
TEST SUITE: None
alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3/exerc2$ kubectl get hpa
NAME          REFERENCE          TARGETS          MINPODS  MAXPODS  REPLICAS  AGE
goodbye-hpa   Deployment/goodbye  cpu: <unknown>/80%  1        20       0         10s
```

```

alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3/exerc2$ kubectl describe deployment goodbye
Name: goodbye
Namespace: default
CreationTimestamp: Wed, 01 Apr 2026 23:29:38 +0300
Labels: app.kubernetes.io/managed-by=Helm
Annotations: deployment.kubernetes.io/revision: 1
             meta.helm.sh/release-name: goodbye
             meta.helm.sh/release-namespace: default
Selector: app=goodbye
Replicas: 1 desired | 1 updated | 1 total | 1 available | 0 unavailable
StrategyType: RollingUpdate
MinReadySeconds: 0
RollingUpdateStrategy: 25% max unavailable, 25% max surge
Pod Template:
  Labels: app=goodbye
  Containers:
    goodbye-kubernetes:
      Image: carvicsforth/hello-kubernetes:1.10
      Port: <none>
      Host Port: <none>
  Limits:
    cpu: 250m

alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3/exerc2$ kubectl get ingress
NAME           CLASS  HOSTS  ADDRESS  PORTS  AGE
goodbye-ingress  nginx  *      80       20s

```

Άσκηση 3

Για να απενεργοποιήσουμε το addon του minikube που ενεργοποίησα προηγουμένως τρέχω την εντολή:

minikube addons disable ingress

```

alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3/exerc2$ minikube addons disable ingress
❌ "The 'ingress' addon is disabled

```

τρέχουμε τα commands από το [artifact HUB](https://artifacthub.io/).

Try again deploying one of the services of the above exercises. What changes are needed in the YAML files to make them work (if any)?

Για λόγους ευκολίας θα αλλάξουμε το αρχείο της άσκησης 1 και θα προσθέσουμε την γραμμή `ingressClassName: nginx` στο `hello-igress.yaml` στα spec του Ingress για να διαλέξουμε τον Controller.

```

alexandrosm@naxi:~/Desktop/csd/8th_sem/hy-548/Assignment3$ kubectl get ingress
NAME           CLASS  HOSTS  ADDRESS      PORTS  AGE
goodbye-ingress  nginx  *      10.102.144.22  80     21m
hello-ingress    nginx  *      10.102.144.22  80     4m22s

```